

## Aula 04

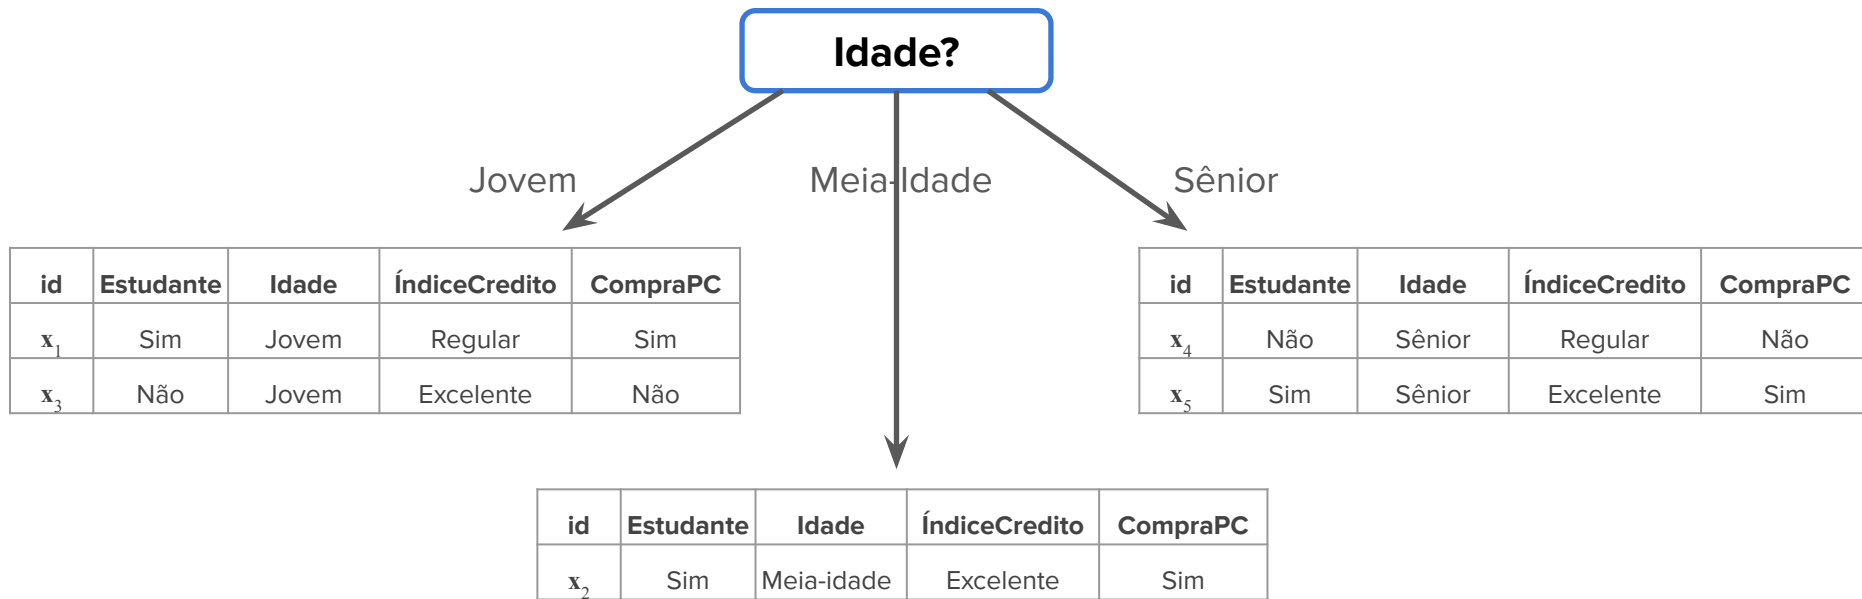
---

# Métodos probabilísticos de classificação. Naïve Bayes.

# Aula passada

## Árvores de decisão: divisão e conquista

id	Estudante	Idade	ÍndiceCredito	CompraPC
$x_1$	Sim	Jovem	Regular	Sim
$x_2$	Sim	Meia-idade	Excelente	Sim
$x_3$	Não	Jovem	Excelente	Não
$x_4$	Não	Sênior	Regular	Não
$x_5$	Sim	Sênior	Excelente	Sim



Ideia: recursivamente tentar melhorar a pureza de uma partição

# Aula passada

## Algoritmos ID3, C4.5 e CART

	Critério de seleção	Tipos de atributos suportados	Lida com valores desconhecidos?	Estratégia de poda?
<b>ID3</b>	Ganho de Informação	Apenas categóricos	Não	Não adota
<b>C4.5</b>	Razão de Ganho	Categóricos e numéricos	Sim	Pessimista
<b>CART</b>	Índice Gini	Categóricos e numéricos	Sim	Custo-complexidade

### Ganho de Informação

$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i),$$

$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j).$$

$$Gain(A) = Info(D) - Info_A(D).$$

### Razão de Ganho

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}.$$

$$SplitInfo_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2 \left( \frac{|D_j|}{|D|} \right).$$

### Índice Gini

$$Gini(D) = 1 - \sum_{i=1}^m p_i^2$$

$$Gini_A(D) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2).$$

# Métodos probabilísticos de classificação

Aprendizado Bayesiano

Introdução ao Algoritmo Naïve Bayes

# Métodos probabilísticos de classificação

- Objetivo da tarefa de classificação: aprender a função\*  $y = f(\mathbf{x})$ 
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$


Aprender um modelo com base nos dados de treinamento que determine a **melhor classe** para uma nova instância dado o seu vetor de atributos

- Métodos probabilísticos:
  - Especialmente úteis quando há incerteza sobre o domínio

Aprender um modelo com base nos dados de treinamento que determine a **classe mais provável** para uma nova instância dado o seu vetor de atributos



# Métodos probabilísticos de classificação

- Objetivo da tarefa de classificação: aprender a função\*  $y = f(\mathbf{x})$ 
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$



# "Classe mais provável"

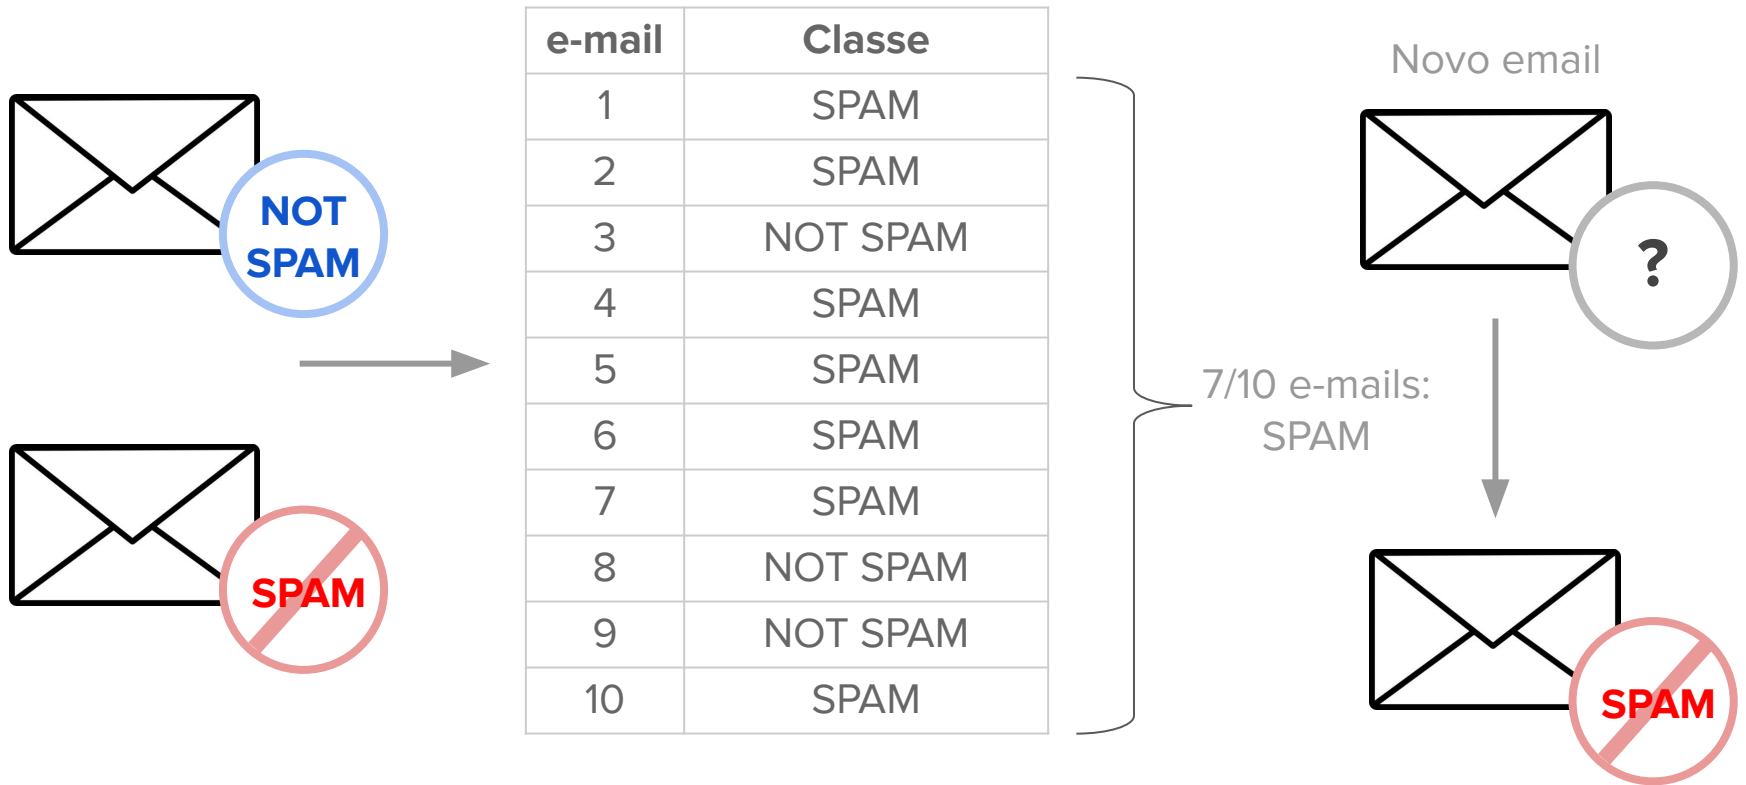
- Intuição básica



e-mail	Classe
1	SPAM
2	SPAM
3	NOT SPAM
4	SPAM
5	SPAM
6	SPAM
7	SPAM
8	NOT SPAM
9	NOT SPAM
10	SPAM

# "Classe mais provável"

- Intuição básica

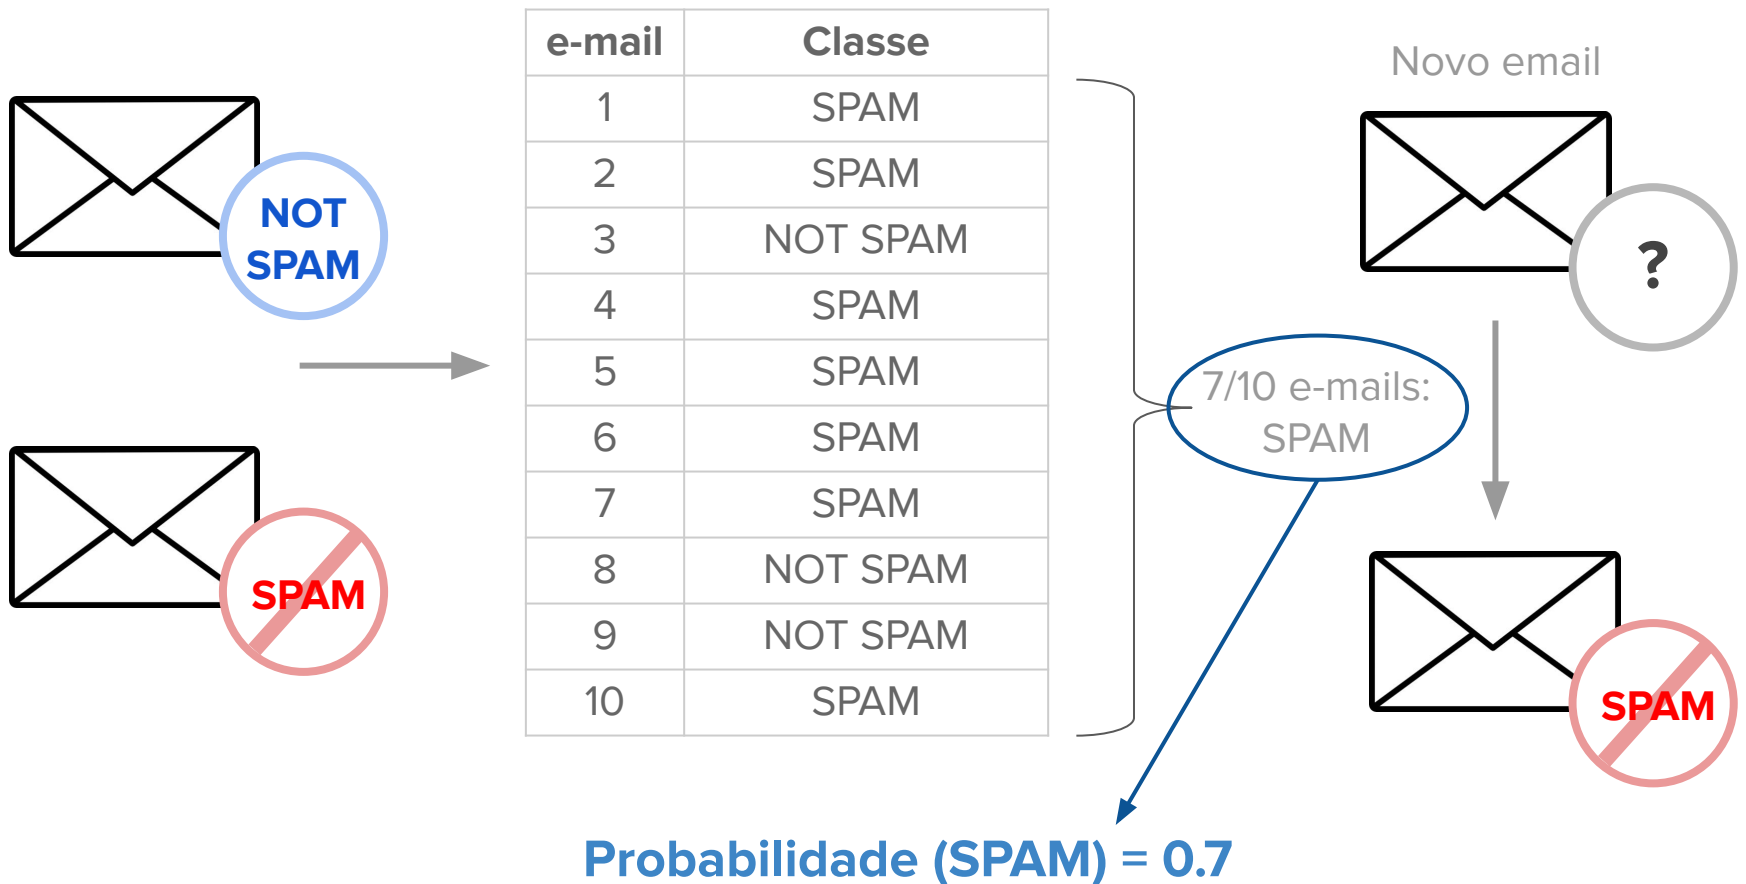


"Supondo um novo e-mail recebido, é mais provável que ele seja SPAM ou NOT SPAM?"





# "Classe mais provável"

- Intuição básica



# "Classe mais provável"


- Intuição básica



e-mail	Conteúdo	Classe
1	"password expired"	SPAM
2	"send password"	SPAM
3	"review conference"	NOT SPAM
4	"password review"	SPAM
5	"review account"	SPAM
6	"account password"	SPAM
7	"send account"	SPAM
8	"conference paper"	NOT SPAM
9	"send paper"	NOT SPAM
10	"expired account"	SPAM





Novo email



"Supondo um novo e-mail recebido, com conteúdo *"review conference paper"*, é mais provável que ele seja SPAM ou NOT SPAM?"



# "Classe mais provável"

- Intuição básica



e-mail	Conteúdo	Classe
1	"password expired"	SPAM
2	"send password"	SPAM
3	"review conference"	NOT SPAM
4	"password review"	SPAM
5	"review account"	SPAM
6	"account password"	SPAM
7	"send account"	SPAM
8	"conference paper"	NOT SPAM
9	"send paper"	NOT SPAM
10	"expired account"	SPAM



Novo email



"Supondo um novo e-mail recebido, com conteúdo *"review conference paper"*, é mais provável que ele seja SPAM ou NOT SPAM?"



# "Classe mais provável"

- Intuição básica



e-mail	Conteúdo	Classe
1	"password expired"	SPAM
2	"send password"	SPAM
3	"review conference"	NOT SPAM
4	"password review"	SPAM
5	"review account"	SPAM
6	"account password"	SPAM
7	"send account"	SPAM
8	"conference paper"	NOT SPAM
9	"send paper"	NOT SPAM
10	"expired account"	SPAM

Novo email




Qual a classe mais provável dado o conteúdo do e-mail?

# Aprendizado Bayesiano

- Assumindo:
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
    - Isto é, seu conteúdo (as palavras contidas no e-mail)
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$ 
    - Isto é, a classe definindo se é SPAM ou NOT SPAM
- Aprendizado Bayesiano visa encontrar a classe  $y_i$  que possui a maior probabilidade de explicar o exemplo de entrada  $\mathbf{x}$


**IF**  $P(\text{"SPAM"} \mid \text{Conteúdo}) < P(\text{"NOT SPAM"} \mid \text{Conteúdo})$



# Aprendizado Bayesiano

- Assumindo:
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
    - Isto é, seu conteúdo (as palavras contidas no e-mail)
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$ 
    - Isto é, a classe definindo se é SPAM ou NOT SPAM
- Aprendizado Bayesiano visa encontrar a classe  $y_i$  que possui a maior probabilidade de explicar o exemplo de entrada  $\mathbf{x}$

**IF**  $P(\text{"SPAM"} \mid \text{Conteúdo}) > P(\text{"NOT SPAM"} \mid \text{Conteúdo})$



# Aprendizado Bayesiano

- Assumindo:
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
    - Isto é, seu conteúdo (as palavras contidas no e-mail)
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$ 
    - Isto é, a classe definindo se é SPAM ou NOT SPAM
- Aprendizado Bayesiano visa encontrar a classe  $y_i$  que possui a maior probabilidade de explicar o exemplo de entrada  $\mathbf{x}$ 
  - Formalmente:

$$y_{MAP} = \underset{i}{\operatorname{argmax}} P(y_i | \mathbf{x})$$

- Retorna a classe  $y_i$  com maior probabilidade de estar associada a  $\mathbf{x}$ , isto é, aquela que possui valor máximo de  $P(y_i | \mathbf{x})$

# Aprendizado Bayesiano

- Assumindo:
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
    - Isto é, seu conteúdo (as palavras contidas no e-mail)
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$ 
    - Isto é, a classe definindo se é SPAM ou NOT SPAM
- Aprendizado Bayesiano visa encontrar a classe  $y_i$  que possui a maior probabilidade de explicar o exemplo de entrada  $\mathbf{x}$ 
  - Formalmente:

$$\underline{y_{MAP}} = \underset{i}{\operatorname{argmax}} \underline{P(y_i | \mathbf{x})}$$

**Maximum a Posteriori** **Probabilidade a posteriori**

- Retorna a classe  $y_i$  com maior probabilidade de estar associada a  $\mathbf{x}$ , isto é, aquela que possui valor máximo de  $P(y_i | \mathbf{x})$



# Aprendizado Bayesiano

- Assumindo:
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
    - Isto é, seu conteúdo (as palavras contidas no e-mail)
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$ 
    - Isto é, a classe definindo se é SPAM ou NOT SPAM

Como calcular  $P(y_i|\mathbf{x})$  ?

$$\underline{y_{MAP}} = \underset{i}{\operatorname{argmax}} \underbrace{P(y_i|\mathbf{x})}$$


Maximum a Posteriori      Probabilidade a posteriori

Teoria da probabilidade  
Teorema de Bayes

# Teoria da Probabilidade

## Axiomas de Kolmogorof

- Considere um evento  $E$  no espaço amostral finito ( $\Omega$ ).
  - $P(E)$  é a probabilidade do evento  $E$  ocorrer, dada pelo número de ocorrências (pontos) favoráveis a  $E$  dividido pelo número total de ocorrências (pontos) no espaço amostral  $\Omega$
- Probabilidade  $P(E)$  satisfaz os axiomas:
  1.  $0 \leq P(E)$
  2. Se  $\Omega$  é o espaço de todos os possíveis eventos, então  $P(\Omega) = 1$
  3. Se  $E_1$  e  $E_2$  são eventos disjuntos, então:




$$P(E_1 \cup E_2) = \underline{P(E_1)} + P(E_2)$$

**Probabilidade a priori (marginal)**

# Teoria da Probabilidade

## Probabilidade Condicional



- Suponha os eventos:
  - A: a primeira bola sorteada é azul
  - B: a segunda bola sorteada é azul
- $P(A) = 2/5$
- $P(B)$ :  $1/4$  se A ocorre;  $2/4$  caso contrário.  $P(B|A) = 1/4$



# Teoria da Probabilidade

## Probabilidade Condicional

- Suponha os eventos:
  - A: a primeira bola sorteada é azul
  - B: a segunda bola sorteada é azul
- $P(A) = 2/5$
- $P(B)$ : 1/4 se A ocorre; 2/4 caso contrário.  $P(B|A) = 1/4$
- Suponha agora o evento:
  - A e B: as duas primeiras bolas sorteadas são azuis
  - Probabilidade conjunta:  $P(A \cap B) = ?$




# Teoria da Probabilidade

## Probabilidade Condicional

- Suponha os eventos:

- A: a primeira bola sorteada é azul
- B: a segunda bola sorteada é azul




- $P(A) = 2/5$

- $P(B)$ : 1/4 se A ocorre; 2/4 caso contrário.  $P(B|A) = 1/4$

- Suponha agora o evento:


- A e B: as duas primeiras bolas sorteadas são azuis
- Probabilidade conjunta:  $P(A \cap B) = P(A) \times P(B|A)$



# Teoria da Probabilidade

## Lei da Probabilidade Condicional

- Supondo  $A$  e  $B$  genéricos



# Teoria da Probabilidade

## Lei da Probabilidade Condicional

- Supondo as probabilidades conjuntas  $P(A \cap B)$  e  $P(B \cap A)$ , define-se as respectivas probabilidades condicionais  $P(A|B)$  e  $P(B|A)$ :

$$P(A \cap B) = P(A|B)P(B)$$



$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(B \cap A) = P(B|A)P(A)$$



$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$

- A seguinte igualdade é verdadeira



$$P(A \cap B) = P(B \cap A)$$

# Teoria da Probabilidade

## Lei da Probabilidade Total

- Se os eventos  $A_1, A_2, \dots, A_n$  são eventos disjuntos mensuráveis cuja união forma uma partição em  $\Omega$ , então para qualquer evento  $B$  no mesmo espaço de probabilidades, temos:

$$P(B) = \sum_{j=1}^n \underbrace{P(B|A_j)}_{\text{Probabilidade condicional}} \underbrace{P(A_j)}_{\text{Probabilidade a priori}}$$





## Exemplo de trabalho: Diagnóstico médico de Malária

- A probabilidade de um médico observar um paciente com malária em Porto Alegre é de 8%
- Um exame para diagnóstico laboratorial da malária possui um grau de incerteza.
  - Em 75% dos casos em que o resultado do exame foi positivo, a doença foi confirmada no paciente (SENSIBILIDADE)
  - Em 96% dos casos em que o resultado do exame foi negativo, o paciente não tinha a doença (ESPECIFICIDADE)

O que podemos dizer sobre um paciente se o teste deu positivo?  
Ele está doente?

## Exemplo de trabalho: Diagnóstico médico de Malária

- A probabilidade de um médico observar um paciente com malária em Porto Alegre é de 8%
- Um exame para diagnóstico laboratorial da malária possui um grau de incerteza.
  - Em 75% dos casos em que o resultado do exame foi positivo, a doença foi confirmada no paciente (SENSIBILIDADE)
  - Em 96% dos casos em que o resultado do exame foi negativo, o paciente não tinha a doença (ESPECIFICIDADE)



**Probabilidade a priori**

$P(\text{Malaria=presente}) = \mathbf{0.08}$

$P(\text{Malaria=ausente}) = 1 - P(\text{Malaria=presente}) = \mathbf{0.92}$

## Exemplo de trabalho: Diagnóstico médico de Malária

- A probabilidade de um médico observar um paciente com malária em Porto Alegre é de 8%
- Um exame para diagnóstico laboratorial da malária possui um grau de incerteza.
  - Em 75% dos casos em que o resultado do exame foi positivo, a doença foi confirmada no paciente (SENSIBILIDADE)
  - Em 96% dos casos em que o resultado do exame foi negativo, o paciente não tinha a doença (ESPECIFICIDADE)



### Probabilidades condicionais

$P(\text{Exame=positivo} \mid \text{Malaria=presente}) = \mathbf{0.75}$

$P(\text{Exame=negativo} \mid \text{Malaria=ausente}) = \mathbf{0.96}$

		Doença	
		presente	ausente
Exame	positivo	75%	?
	negativo	?	96%

## Exemplo de trabalho: Diagnóstico médico de Malária

- A probabilidade de um médico observar um paciente com malária em Porto Alegre é de 8%
- Um exame para diagnóstico laboratorial da malária possui um grau de incerteza.
  - Em 75% dos casos em que o resultado do exame foi positivo, a doença foi confirmada no paciente (SENSIBILIDADE)
  - Em 96% dos casos em que o resultado do exame foi negativo, o paciente não tinha a doença (ESPECIFICIDADE)

### Probabilidades condicionais

$P(\text{Exame=positivo} \mid \text{Malaria=presente}) = 0.75$

$P(\text{Exame=negativo} \mid \text{Malaria=ausente}) = 0.96$

Eventos  
complementares.  
Somam = 1

		Doença	
		presente	ausente
Exame	positivo	75%	?
	negativo	?	96%

## Exemplo de trabalho: Diagnóstico médico de Malária

- A probabilidade de um médico observar um paciente com malária em Porto Alegre é de 8%
- Um exame para diagnóstico laboratorial da malária possui um grau de incerteza.
  - Em 75% dos casos em que o resultado do exame foi positivo, a doença foi confirmada no paciente (SENSIBILIDADE)
  - Em 96% dos casos em que o resultado do exame foi negativo, o paciente não tinha a doença (ESPECIFICIDADE)



### Probabilidades condicionais

$P(\text{Exame=positivo} \mid \text{Malaria=presente}) = 0.75$

$P(\text{Exame=negativo} \mid \text{Malaria=ausente}) = 0.96$

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

# Exemplo de trabalho: Diagnóstico médico de Malária

- Pela Lei da Probabilidade Total:

$$P(A) = \sum_{j=1}^n P(A|B_j)P(B_j)$$

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

- Podemos calcular a probabilidade a priori da variável Exame:

$$\begin{aligned} P(\text{Exame=positivo}) &= P(\text{Exame=positivo} \mid \text{Malaria=presente}) * P(\text{Malaria=presente}) \\ &\quad + P(\text{Exame=positivo} \mid \text{Malaria=ausente}) * P(\text{Malaria=ausente}) \\ &= 0.75 * 0.08 + 0.04 * 0.92 = \mathbf{0.0968} \end{aligned}$$

$$\begin{aligned} P(\text{Exame=negativo}) &= P(\text{Exame=negativo} \mid \text{Malaria=presente}) * P(\text{Malaria=presente}) \\ &\quad + P(\text{Exame=negativo} \mid \text{Malaria=ausente}) * P(\text{Malaria=ausente}) \\ &= 0.25 * 0.08 + 0.96 * 0.92 = \mathbf{0.9032} \end{aligned}$$

# Exemplo de trabalho:

## Diagnóstico médico de Malária

- Com base nos cálculos e no enunciado, temos:

### Probabilidades a priori

$$P(\text{Malaria=presente}) = 0.08$$

$$P(\text{Malaria=ausente}) = 0.92$$

$$P(\text{Exame=positivo}) = 0.0968$$

$$P(\text{Exame=negativo}) = 0.9032$$

### Probabilidades condicionais (verossimilhança)

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

O que podemos dizer sobre o paciente se o teste deu positivo?  
Ele está doente? Qual a probabilidade  $P(\text{Malaria=presente} \mid \text{exame=positivo})$ ?

# Teorema de Bayes

Cálculo da Probabilidade a Posteriori  
[ou "como calcular  $P(A | B)$  se eu sei  $P(B | A)$ "]

- Dada a igualdade

$$P(A \cap B) = P(B \cap A)$$

- Da definição de probabilidade conjunta, temos que:

$$P(A|B)P(B) = P(B|A)P(A)$$



**Teorema de  
Bayes**

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$



# Teorema de Bayes

Cálculo da Probabilidade a Posteriori

[ou "como calcular  $P(A | B)$  se eu sei  $P(B | A)$ "]

Probabilidade  
**a priori**  
(conhecimento prévio)



**Evidências**  
(observações)



Probabilidade  
**a posteriori**


**Teorema de  
Bayes**

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

# Aprendizado Bayesiano

## na classificação

- Assumindo:
  - $\mathbf{x}$  é a entrada, um vetor com valores dos atributos preditivos
  - $y$  é a saída, um valor categórico em  $\{c_1, c_2, \dots, c_m\}$
- Objetivo:
  - Encontrar a classe que maximize a probabilidade a posteriori

$$y_{MAP} = \underset{i}{\operatorname{argmax}} \underbrace{P(y_i|\mathbf{x})}$$


$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

$$\frac{P(A|B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$

Teorema de Bayes

# Aprendizado Bayesiano

## na classificação

- Componentes:

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

$\mathbf{x}$ : sintomas de um paciente

$y$ : paciente possui malária?

- $P(y)$ : probabilidade a priori de cada classe
  - Probabilidade estimada antes de qualquer evidência extra, com base em conhecimento do domínio
  - Quais classes são comuns e quais são raras?
  - *A priori, é mais provável que um paciente atendido em Porto Alegre tenha Gripe do que Malária, por exemplo..*

# Aprendizado Bayesiano

## na classificação

- Componentes:

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

$\mathbf{x}$ : sintomas de um paciente

$y$ : paciente possui malária?

- $P(\mathbf{x}|y)$ : modelo condicionado à classe
  - Probabilidade condicional de  $\mathbf{x}$  dado  $y$
  - Descreve o quão provável é ter uma observação  $\mathbf{x}$  para a classe  $y$
  - *Assumindo que o paciente tem Malária, os sintomas são plausíveis?*

# Aprendizado Bayesiano

## na classificação

- Componentes:

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

Teoria da Probabilidade Total

$\mathbf{x}$ : sintomas de um paciente  
 $y$ : paciente possui malária?

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{\sum_{i=1}^m P(\mathbf{x}|y_i)P(y_i)}$$

- $P(\mathbf{x})$ : probabilidade a priori de uma observação
  - Normaliza as probabilidades entre as observações
  - Não está conectada a nenhuma classe específica: é uma constante
  - Como não está conectado a uma classe específica, não afeta a predição de qual classe é mais provável ( $\arg \max$ ) e por isso é normalmente ignorado no cálculo

# Exemplo de trabalho:

## Diagnóstico médico de Malária

- Com base nos cálculos e no enunciado, temos:

### Probabilidades a priori

$$P(\text{Malaria=presente}) = 0.08$$

$$P(\text{Malaria=ausente}) = 0.92$$

$$P(\text{Exame=positivo}) = 0.0968$$

$$P(\text{Exame=negativo}) = 0.9032$$

### Probabilidades condicionais (verossimilhança)

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

### Probabilidades condicionais (Verossimilhança)

## Retomando....

O que podemos dizer sobre o paciente se o teste deu positivo?  
Ele está doente? Qual a probabilidade  $P(\text{Malaria=presente} \mid \text{exame=positivo})$ ?

# Exemplo de trabalho:

## Diagnóstico médico de Malária

O que podemos dizer sobre o paciente se o teste deu positivo?  
Ele está doente? Qual a probabilidade  $P(\text{Malária=presente} \mid \text{exame=positivo})$ ?

### Probabilidades a priori

$$P(\text{Malária=presente}) = 0.08$$

$$P(\text{Malária=ausente}) = 0.92$$

$$P(\text{Exame=positivo}) = 0.0968$$

$$P(\text{Exame=negativo}) = 0.9032$$

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

Probabilidades condicionais  
(Verossimilhança)

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

Teorema de Bayes

$$P(\text{Malária=presente} \mid \text{Exame=positivo})$$

$$= P(\text{Exame} = \text{positivo} \mid \text{Malária} = \text{presente}) * P(\text{Malária=presente})$$
$$= 0.75 * 0.08 = 0.06$$

$$P(\text{Malária} = \text{ausente} \mid \text{Exame=positivo})$$

$$= P(\text{Exame} = \text{positivo} \mid \text{Malária} = \text{ausente}) * P(\text{Malária=ausente})$$
$$= 0.04 * 0.92 = 0.0368 = 0.0368$$

# Exemplo de trabalho:

## Diagnóstico médico de Malária

O que podemos dizer sobre o paciente se o teste deu positivo?  
Ele está doente? Qual a probabilidade  $P(\text{Malária=presente} \mid \text{exame=positivo})$ ?

### Probabilidades a priori

$$P(\text{Malária=presente}) = 0.08$$

$$P(\text{Malária=ausente}) = 0.92$$

$$P(\text{Exame=positivo}) = 0.0968$$

$$P(\text{Exame=negativo}) = 0.9032$$

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

Probabilidades condicionais  
(Verossimilhança)

$$\begin{aligned} P(\text{Malária=presente} \mid \text{Exame=positivo}) \\ &= P(\text{Exame = positivo} \mid \text{Malária=presente}) * P(\text{Malária=presente}) \\ &= 0.75 * 0.08 = \mathbf{0.06} \end{aligned}$$

0.06 > 0.0368:  
Por inferência Bayesiana, a classe mais provável é "Malária presente":

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

Teorema de Bayes

$$\begin{aligned} P(\text{Malária = ausente} \mid \text{Exame=positivo}) \\ &= P(\text{Exame = positivo} \mid \text{Malária = ausente}) * P(\text{Malária=ausente}) \\ &= 0.04 * 0.92 = 0.0368 = \mathbf{0.0368} \end{aligned}$$



# Exemplo de trabalho:

## Diagnóstico médico de Malária

O que podemos dizer sobre o paciente se o teste deu positivo?  
Ele está doente? Qual a probabilidade  $P(\text{Malária=presente} \mid \text{exame=positivo})$ ?

### Probabilidades a priori

$$P(\text{Malária=presente}) = 0.08$$

$$P(\text{Malária=ausente}) = 0.92$$

$$P(\text{Exame=positivo}) = 0.0968$$

$$P(\text{Exame=negativo}) = 0.9032$$

	Doença	
	presente	ausente
Exame	positivo	75% 4%
	negativo	25% 96%

Probabilidades condicionais  
(Verossimilhança)

$$P(\text{Malária=presente} \mid \text{Exame=positivo})$$

$$= P(\text{Exame = positivo} \mid \text{Malária = presente}) * P(\text{Malária=presente})$$

$$= 0.75 * 0.08 = 0.06$$

Divisão por  $P(\text{Exame=positivo})$

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

Teorema de Bayes

$$P(\text{Malária = ausente} \mid \text{Exame=positivo})$$

$$= P(\text{Exame = positivo} \mid \text{Malária = ausente}) * P(\text{Malária=ausente})$$

$$= 0.04 * 0.92 = 0.0368$$

# Exemplo de trabalho:

## Diagnóstico médico de Malária

O que podemos dizer sobre o paciente se o teste deu positivo?  
Ele está doente? Qual a probabilidade  $P(\text{Malária=presente} \mid \text{exame=positivo})$ ?

### Probabilidades a priori

$$P(\text{Malária=presente}) = 0.08$$

$$P(\text{Malária=ausente}) = 0.92$$

$$P(\text{Exame=positivo}) = 0.0968$$

$$P(\text{Exame=negativo}) = 0.9032$$

		Doença	
		presente	ausente
Exame	positivo	75%	4%
	negativo	25%	96%

Probabilidades condicionais  
(Verossimilhança)

$$P(y|\mathbf{x}) = \frac{P(\mathbf{x}|y)P(y)}{P(\mathbf{x})}$$

Teorema de Bayes

$$P(\text{Malária=presente} \mid \text{Exame=positivo})$$

$$= P(\text{Exame} = \text{positivo} \mid \text{Malária} = \text{presente}) * P(\text{Malária=presente})$$

$$= 0.75 * 0.08 = 0.06$$

$$= 0.06 / 0.0968 = \mathbf{0.6198}$$

$$P(\text{Malária} = \text{ausente} \mid \text{Exame=positivo})$$

$$= P(\text{Exame} = \text{positivo} \mid \text{Malária} = \text{ausente}) * P(\text{Malária=ausente})$$

$$= 0.04 * 0.92 = 0.0368$$

$$= 0.0368 / 0.0968 = \mathbf{0.3802}$$

Probabilidades a posteriori (Soma = 1)

# Problema do dia

- Um restaurante deseja descobrir sob que condições climáticas se vende mais Feijoada ou Filé à Parmegiana.
- Objetivo: preparar melhor a *mise en place* da cozinha



# Problema do dia

- Um restaurante deseja descobrir sob que condições climáticas se vende mais Feijoada ou Filé à Parmegiana.
- Objetivo: preparar melhor a *mise en place* da cozinha



*Mise en place* (posta no lugar): "pôr em ordem"; organização de utensílios, ingredientes, etc... que precede a preparação de uma receita

- A equipe de vendas coletou os seguintes dados (*próximo slide*)

# Problema do dia

Classe

	$x_k^1$	$x_k^2$	$x_k^3$	$x_k^4$	$y_k$
	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoada
$x_7$	nublado	quente	alta	não	feijoada
$x_8$	nublado	quente	normal	não	feijoada
$x_9$	nublado	moderado	alta	sim	feijoada
$x_{10}$	chuva	frio	normal	não	feijoada
$x_{11}$	chuva	moderado	alta	não	feijoada
$x_{12}$	chuva	moderado	normal	não	feijoada
$x_{13}$	sol	frio	normal	não	feijoada
$x_{14}$	sol	moderado	normal	sim	feijoada

## Classificação probabilística

# Estimativa Maximum a Posteriori

- Considerando um exemplo desconhecido  $\mathbf{x}$ , para cada classe  $y_i$  em  $\{c_1, c_2, \dots, c_m\}$ , calcule:

$$P(y_i|\mathbf{x}) = \frac{P(\mathbf{x}|y_i)P(y_i)}{P(\mathbf{x})}$$

- Retornando como saída:

$$y_{MAP} = \underset{i}{\operatorname{argmax}} P(y_i|\mathbf{x})$$

# Classificação probabilística

## Estimativa Maximum a Posteriori

- Considerando um exemplo desconhecido  $\mathbf{x}$ , para cada classe  $y_i$  em  $\{c_1, c_2, \dots, c_m\}$ , calcule:

$$P(y_i|\mathbf{x}) = \frac{P(\mathbf{x}|y_i)P(y_i)}{\underline{P(\mathbf{x})}}$$

Para encontrar a classe com maior probabilidade, este termo não precisa ser calculado, pois é constante para todas as classes

- Retornando como saída:

$$\underline{y_{MAP}} = \underset{i}{\operatorname{argmax}} P(y_i|\mathbf{x})$$

**Maximum a Posteriori**

# Classificação probabilística

## Estimativa Maximum a Posteriori

- Considerando um exemplo desconhecido  $\mathbf{x}$ , para cada classe  $y_i$  em  $\{c_1, c_2, \dots, c_m\}$ , calcule:

$$P(y_i|\mathbf{x}) = \frac{P(\mathbf{x}|y_i) \cancel{P(y_i)}}{\cancel{P(\mathbf{x})}}$$

Nos casos em que podemos assumir que esta probabilidade é uniforme (ou quando é difícil estimá-la), é comum ignorarmos este termo

- Retornando como saída:

$$\begin{array}{l} \text{Maximum a Posteriori} \\ \underline{y_{MAP}} = \underset{i}{\operatorname{argmax}} P(y_i|\mathbf{x}) \\ \downarrow i \\ \underline{y_{ML}} = \underset{i}{\operatorname{argmax}} P(\mathbf{x}|y_i) \\ \text{Maximum Likelihood} \end{array} \quad \begin{array}{l} \text{Simplificação} \end{array}$$

O método MAP se resume a encontrar a hipótese que maximiza a verossimilhança  $P(\text{Dados} | \text{Hipótese})$ : tem aplicabilidade limitada pois o cálculo  $P(x_1, \dots, x_d | y)$  para conjuntos de dados com muitos atributos é computacionalmente custoso ou impraticável



# Naïve Bayes

- Ideia "naïve": assumir que os valores dos atributos de um exemplo  $\mathbf{x}$  são independentes entre si dada a classe  $y$
- Adota a suposição de independência condicional:

$$P(\mathbf{x}|y) = P(x^1, \dots, x^d|y) = \underbrace{\prod_{j=1}^d P(x^j|x^1, \dots, x^{j-1}, y)}_{\text{Regra da Cadeia (exata)}} = \underbrace{\prod_{j=1}^d P(x^j|y)}_{\text{Independência condicional}}$$

# Naïve Bayes

- Ideia "naïve": assumir que os valores dos atributos de um exemplo  $\mathbf{x}$  são independentes entre si dada a classe  $y$
- Adota a suposição de independência condicional:

$$P(\mathbf{x}|y) = P(x^1, \dots, x^d|y) = \underbrace{\prod_{j=1}^d P(x^j|x^1, \dots, x^{j-1}, y)}_{\text{Regra da Cadeia (exata)}} = \underbrace{\prod_{j=1}^d P(x^j|y)}_{\text{Independência condicional}}$$

- Substituindo na fórmula do Teorema de Bayes:

$$P(y_i|\mathbf{x}) = \frac{P(\mathbf{x}|y_i)P(y_i)}{P(\mathbf{x})} \longrightarrow P(y_i|\mathbf{x}) = P(y_i) \prod_{j=1}^d P(x^j|y_i)$$

# Naïve Bayes

- Ideia "naïve": assumir que os valores dos atributos de um exemplo  $\mathbf{x}$  são independentes entre si dada a classe  $y$
- Adota a suposição de independência condicional:

$$P(\mathbf{x}|y) = P(x^1, \dots, x^d|y) = \prod_{j=1}^d P(x^j|x^1, \dots, x^{j-1}, y) = \prod_{j=1}^d P(x^j|y)$$

Como estimar as probabilidades envolvidas?

- Substituindo na fórmula do Teorema de Bayes:

$$P(y_i|\mathbf{x}) = \frac{P(\mathbf{x}|y_i)P(y_i)}{\cancel{P(\mathbf{x})}} \longrightarrow P(y_i|\mathbf{x}) = P(y_i) \prod_{j=1}^d P(x^j|y_i)$$

# Naïve Bayes

- Todas as **probabilidades utilizadas são estimadas a partir dos dados de treinamento**  $\mathbf{D} = \{(\mathbf{x}_k, f(\mathbf{x}_k)), k = 1, \dots, n\}$ , com cada exemplo dado por um vetor de atributos  $\mathbf{x}_k = \{x_k^1, x_k^2, \dots, x_k^d\}$  formado pelo valor observado para os  $d$  atributos  $A_1, \dots, A_d$

$$P(y_i|\mathbf{x}) = P(y_i) \prod_{j=1}^d P(x^j|y_i)$$

- $P(y_i)$  : probabilidade da classe  $y_i$  no conjunto de treinamento
  - Calculada como a razão entre quantas instâncias pertencem à classe  $y_i$  e o número total de exemplos no conjunto  $D$
- $P(x^j|y_i)$  : probabilidade do valor de atributo  $A_j$  assumir um valor  $x^j$  dada a distribuição de classe  $y_i$ 
  - cálculo depende do tipo do atributo  $A_j$ , categórico ou numérico (contínuo). veremos mais adiante...

# Aplicação de Naïve Bayes para classificação de dados estruturados

Estimativa das probabilidades com atributos categóricos,  
numéricos e mistos.

# Algoritmo Naïve Bayes

## Entradas:

Conjunto de treinamento,  $\mathbf{D} = \{(\mathbf{x}_k, f(\mathbf{x}_k)), k = 1, \dots, n\}$

Instância de teste, com rótulo desconhecido,  $\mathbf{t} = \{\mathbf{x}_t, y_t = ?\}$

## Saída:

Rótulo estimado para a entrada  $\mathbf{t}, y_t$

1. Calcule a probabilidade a priori  $P(y_i)$  para cada classe  $y_i$  em  $\{c_1, c_2, \dots, c_m\}$
2. Para cada classe  $y_i$ , faça:
  3. Inicialize uma variável acumuladora para o produto (prod<sub>i</sub>) com valor 1
  4. Para cada atributo preditivo  $x_t^j$  em  $\mathbf{x}_t$ , com  $j = 1, \dots, d$  faça:
    5. Recupere os exemplos de  $D$  com  $x_k^j = x_t^j$
    6. Organize os exemplos recuperados de acordo com seus rótulos  $y_k$
    7. Calcule  $P(x_k^j | y_i)$ , com  $y_i = y_k$ , e atualize prod<sub>i</sub> como  $\text{prod}_i = \text{prod}_i * P(x_k^j | y_i)$
  8. Faça  $P(y_i | \mathbf{x}_t) = P(y_i) * \text{prod}_i$
9. Encontre a classe  $y_i$  que **maximize**  $P(y_i | \mathbf{x}_t)$  e a retorne como rótulo  $y_t$

# Algoritmo Naïve Bayes

## Entradas:

Conjunto de treinamento,  $\mathbf{D} = \{(\mathbf{x}_k, f(\mathbf{x}_k)), k = 1, \dots, n\}$

Instância de teste, com rótulo desconhecido,  $\mathbf{t} = \{\mathbf{x}_t, y_t = ?\}$

**Todas as probabilidades podem ser pré-computadas e armazenadas em uma etapa de "treinamento" do modelo**

1. Calcule a probabilidade a priori  $P(y_i)$  para cada classe  $y_i$  em  $\{c_1, c_2, \dots, c_m\}$
2. Para cada classe  $y_i$ , faça:
  3. Inicialize uma variável acumuladora para o produto (prod<sub>i</sub>) com valor 1
  4. Para cada atributo preditivo  $x_t^j$  em  $\mathbf{x}_t$ , com  $j = 1, \dots, d$  faça:
    5. Recupere os exemplos de  $D$  com  $x_k^j = x_t^j$
    6. Organize os exemplos recuperados de acordo com seus rótulos  $y_k$
    7. Calcule  $P(x_k^j | y_i)$ , com  $y_i = y_k$ , e atualize prod<sub>i</sub> como  $\text{prod}_i = \text{prod}_i * P(x_k^j | y_i)$
  8. Faça  $P(y_i | \mathbf{x}_t) = P(y_i) * \text{prod}_i$
9. Encontre a classe  $y_i$  que **maximize**  $P(y_i | \mathbf{x}_t)$  e a retorne como rótulo  $y_t$

# Algoritmo Naïve Bayes

## com atributos categóricos

- Um restaurante deseja descobrir sob que condições climáticas se vende mais Feijoada ou Filé à Parmegiana.
- Objetivo: preparar melhor a *mise en place* da cozinha





# Algoritmo Naïve Bayes

## com atributos categóricos

	$x_k^1$	$x_k^2$	$x_k^3$	$x_k^4$	$y_k$
	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoada
$x_7$	nublado	quente	alta	não	feijoada
$x_8$	nublado	quente	normal	não	feijoada
$x_9$	nublado	moderado	alta	sim	feijoada
$x_{10}$	chuva	frio	normal	não	feijoada
$x_{11}$	chuva	moderado	alta	não	feijoada
$x_{12}$	chuva	moderado	normal	não	feijoada
$x_{13}$	sol	frio	normal	não	feijoada
$x_{14}$	sol	moderado	normal	sim	feijoada

Classe

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

Objetivo: Encontrar a classe  $y_i$  que **maximize**  $P(y_i | x_t)$  e a retornar como rótulo  $y_t$

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

$P(\text{feijoadada} | x_t) ?$

$P(\text{parmegiana} | x_t) ?$

# Algoritmo Naïve Bayes com atributos categóricos

1. Calcule a probabilidade a priori  $P(y_i)$  para cada classe  $y_i$  em  $\{c_1, c_2, \dots, c_m\}$ :

14 instâncias ao total

5 instâncias da classe parmegiana

9 instâncias da classe feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

2. Inicializar os produtórios para cada classe

$$\text{prod}_p = 1$$

$$\text{prod}_f = 1$$

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 1$$

$$\text{prod}_f = 1$$

4. Avaliar cada atributo preditivo, calculando sua probabilidade condicionada à cada classe seguindo os passos 5, 6 e 7 do algoritmo

- Encontrar todas as instâncias com mesmo valor para o atributo preditivo analisado na instância de teste
- Contar as ocorrências de cada classe para este valor de atributo, calculando  $P(x^j | y_i)$

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 1$$

$$\text{prod}_f = 1$$

- 5 exemplos possuem  $x_k^1 = \text{sol}$
- $P(\text{sol} \mid \text{parmegiana}) = 3/5 = 0.6$
- $P(\text{sol} \mid \text{feijoadada}) = 2/9 = 0.22$

$$\text{prod}_p = \text{prod}_p * P(\text{sol} \mid \text{parmegiana}) = 0.6$$

$$\text{prod}_f = \text{prod}_f * P(\text{sol} \mid \text{feijoadada}) = 0.22$$

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 0.6$$

$$\text{prod}_f = 0.22$$

- 4 exemplos possuem  $x_k^2 = \text{frio}$
- $P(\text{frio} \mid \text{parmegiana}) = 1/5 = 0.2$
- $P(\text{frio} \mid \text{feijoadada}) = 3/9 = 0.33$

$$\text{prod}_p = \text{prod}_p * P(\text{frio} \mid \text{parmegiana}) = 0.12$$

$$\text{prod}_f = \text{prod}_f * P(\text{frio} \mid \text{feijoadada}) = 0.0726$$

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 0.12$$

$$\text{prod}_f = 0.0726$$

- 7 exemplos possuem  $x_k^3 = \text{normal}$
- $P(\text{normal} \mid \text{parmegiana}) = 1/5 = 0.2$
- $P(\text{normal} \mid \text{feijoadada}) = 6/9 = 0.66$

$$\text{prod}_p = \text{prod}_p * P(\text{normal} \mid \text{parmegiana}) = 0.024$$

$$\text{prod}_f = \text{prod}_f * P(\text{normal} \mid \text{feijoadada}) = 0.0479$$

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---



# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 0.024$$

$$\text{prod}_f = 0.0479$$

- 6 exemplos possuem  $x_k^4 = \text{sim}$
- $P(\text{sim} \mid \text{parmegiana}) = 3/5 = 0.6$
- $P(\text{sim} \mid \text{feijoadada}) = 3/9 = 0.33$

$$\text{prod}_p = \text{prod}_p * P(\text{sim} \mid \text{parmegiana}) = 0.0144$$

$$\text{prod}_f = \text{prod}_f * P(\text{sim} \mid \text{feijoadada}) = 0.0158$$

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 0.0144$$

$$\text{prod}_f = 0.0158$$

8. Calcular a probabilidade a posteriori para cada classe

$$\begin{aligned}
 P(\text{feijoadada} \mid x_t) &= \text{prod}_f * P(\text{feijoadada}) \\
 &= 0.0158 * 0.64 \\
 &= 0.011
 \end{aligned}$$

$$\begin{aligned}
 P(\text{parmegiana} \mid x_t) &= \text{prod}_p * P(\text{parmegiana}) \\
 &= 0.0144 * 0.36 \\
 &= 0.005
 \end{aligned}$$

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 0.0144$$

$$\text{prod}_f = 0.0158$$

8. Calcular a probabilidade a posteriori para cada classe

$$\begin{aligned} P(\text{feijoadada} | x_t) &= \text{prod}_f * P(\text{feijoadada}) \\ &= 0.0158 * 0.64 \\ &= \mathbf{0.010112} \end{aligned}$$

$$\begin{aligned} P(\text{parmegiana} | x_t) &= \text{prod}_p * P(\text{parmegiana}) \\ &= 0.0144 * 0.36 \\ &= 0.005184 \end{aligned}$$

**A classe de maior probabilidade a posteriori é feijoadada, assim  $y_t = \text{feijoadada}$**

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	?
-------	-----	------	--------	-----	---

# Algoritmo Naïve Bayes com atributos categóricos

	Previsão	Temperatura	Umidade	Vento	Prato
$x_1$	chuva	frio	normal	sim	parmegiana
$x_2$	chuva	moderado	alta	sim	parmegiana
$x_3$	sol	quente	alta	não	parmegiana
$x_4$	sol	quente	alta	sim	parmegiana
$x_5$	sol	moderado	alta	não	parmegiana
$x_6$	nublado	frio	normal	sim	feijoadada
$x_7$	nublado	quente	alta	não	feijoadada
$x_8$	nublado	quente	normal	não	feijoadada
$x_9$	nublado	moderado	alta	sim	feijoadada
$x_{10}$	chuva	frio	normal	não	feijoadada
$x_{11}$	chuva	moderado	alta	não	feijoadada
$x_{12}$	chuva	moderado	normal	não	feijoadada
$x_{13}$	sol	frio	normal	não	feijoadada
$x_{14}$	sol	moderado	normal	sim	feijoadada

Instância de teste  $x_t$

$x_t$	sol	frio	normal	sim	<b>feijoadada</b>
-------	-----	------	--------	-----	-------------------

$$P(\text{parmegiana}) = 5/14 = 0.36$$

$$P(\text{feijoadada}) = 9/14 = 0.64$$

$$\text{prod}_p = 0.0144$$

$$\text{prod}_f = 0.0158$$

8. Calcular a probabilidade a posteriori para cada classe

$$\begin{aligned}
 P(\text{feijoadada} | x_t) &= \text{prod}_f * P(\text{feijoadada}) \\
 &= 0.0158 * 0.64 \\
 &= \mathbf{0.011}
 \end{aligned}$$

$$\begin{aligned}
 P(\text{parmegiana} | x_t) &= \text{prod}_p * P(\text{parmegiana}) \\
 &= 0.0144 * 0.36 \\
 &= 0.005
 \end{aligned}$$

A classe de maior probabilidade a posteriori é feijoadada, assim  $y_t = \text{feijoadada}$

# O problema da frequência zero

- Para uma nova instância  $x_t = \{ \text{chuva, quente, alta, não, ?} \}$ , haveria chance de ser predita como Parmegiana?
- Dado que as probabilidades são estimadas a partir dos dados de treinamento, quando a frequência de um determinado valor de atributo é zero para uma classe, a Probabilidade  $P(x^j|y_i) = 0$

Previsão	Temperatura	Umidade	Vento	Prato
chuva	frio	normal	sim	parmegiana
chuva	moderado	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	moderado	alta	sim	parmegiana
nublado	frio	normal	sim	feijoada
nublado	quente	alta	não	feijoada
nublado	quente	normal	não	feijoada

# O problema da frequência zero

- Para uma nova instância  $x_t = \{ \text{chuva, quente, alta, não, ?} \}$ , haveria chance de ser predita como Parmegiana?
- Dado que as probabilidades são estimadas a partir dos dados de treinamento, quando a frequência de um determinado valor de atributo é zero para uma classe, a Probabilidade  $P(x^j|y_i) = 0$
- $x_t$  nunca seria predita como Parmegiana pois  $P(\text{vento=não}|Parmegiana)=0$
- Solução: nunca permitir zero!

Previsão	Temperatura	Umidade	Vento	Prato
chuva	frio	normal	sim	parmegiana
chuva	moderado	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	moderado	alta	sim	parmegiana
nublado	frio	normal	sim	feijoada
nublado	quente	alta	não	feijoada
nublado	quente	normal	não	feijoada

# Correção de Laplace

Solucionando o problema da frequência zero

- **Correção de Laplace:** assumimos ter uma instância a mais para cada valor possível do atributo com referência à classe analisada (efeito negligenciável para grandes conjuntos D)

$$P(\text{vento}=\text{sim}|\text{Parmegiana})=(5+1)/(\mathbf{5+2})$$

$$P(\text{vento}=\text{não}|\text{Parmegiana})=(0+1)/(\mathbf{5+2})$$

5 exemplos

$$P(\text{vento}=\text{sim}|\text{Feijoada})=(1+1)/(\mathbf{3+2})$$

$$P(\text{vento}=\text{não}|\text{Feijoada})=(2+1)/(\mathbf{3+2})$$

3 exemplos

Previsão	Temperatura	Umidade	Vento	Prato
chuva	frio	normal	sim	parmegiana
chuva	moderado	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	moderado	alta	sim	parmegiana
nublado	frio	normal	sim	feijoada
nublado	quente	alta	não	feijoada
nublado	quente	normal	não	feijoada

# Correção de Laplace

Solucionando o problema da frequência zero

- **Correção de Laplace:** assumimos ter uma instância a mais para cada valor possível do atributo com referência à classe analisada (efeito negligenciável para grandes conjuntos D)

$$P(\text{vento}=\text{sim}|\text{Parmegiana})=(5+1)/(5+2)$$

$$P(\text{vento}=\text{não}|\text{Parmegiana})=(0+1)/(5+2)$$

5 exemplos

$$P(\text{vento}=\text{sim}|\text{Feijoada})=(1+1)/(3+2)$$

$$P(\text{vento}=\text{não}|\text{Feijoada})=(2+1)/(3+2)$$

3 exemplos

2 instâncias com vento = não

+

1 instância "extra" para a este valor de atributo e a classe "feijoada"

3 instâncias ao total na classe "feijoada"

+

2 instâncias extras, uma para cada valor possível do atributo vento (i.e., "sim" e não")

Previsão	Temperatura	Umidade	Vento	Prato
chuva	frio	normal	sim	parmegiana
chuva	moderado	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	quente	alta	sim	parmegiana
sol	moderado	alta	sim	parmegiana
nublado	frio	normal	sim	feijoada
nublado	quente	alta	não	feijoada
nublado	quente	normal	não	feijoada



# Estimativa das probabilidades no algoritmo Naïve Bayes com atributos categóricos

- Aspectos principais
  - A **probabilidade a priori** de cada classe pode ser estimada facilmente como uma contagem do número de exemplos associados a classe  $y_i$ ,  $|y_i|$  e o número total de exemplos  $|D|$ :

$$P(y_i) = \frac{|y_i|}{|D|}, y_i \in \{c_1, \dots, c_m\}$$

- Para atributos categóricos, o conjunto de valores possíveis é **enumerável**. O cálculo da **probabilidade condicional** de se observar um determinado valor de atributo dado que o exemplo pertence a uma classe  $y_i$  envolve manter uma variável acumuladora do produtório para cada classe e contabilizar, para cada atributo  $x_k^j$ 
  - Número de exemplos com  $x_k^j = x_t^j$  e  $y_k = y_i$ , dividido por  $|y_i|$

# Estimativa das probabilidades no algoritmo Naïve Bayes com atributos categóricos

- Aspectos principais
  - A **probabilidade a priori** de cada classe pode ser estimada facilmente como uma contagem do número de exemplos associados a classe  $y_i$ ,  $|y_i|$  e o número total de exemplos  $|D|$ :

$$P(y_i) = \frac{|y_i|}{|D|}, y_i \in \{c_1, \dots, c_m\}$$

- Para atributos categóricos, o conjunto de valores possíveis é **enumerável**. O cálculo da **probabilidade condicional** de se observar um determinado valor de atributo dado que o exemplo pertence a uma classe  $y_i$  envolve manter uma variável acumuladora do produtório para cada classe e contabilizar, para cada atributo  $x_k^j$ 
  - Número de exemplos com  $x_k^j = x_t^j$  e  $y_k = y_i$ , dividido por  $|y_i|$

Como proceder com o cálculo da probabilidade condicional quando o atributo é numérico contínuo? *Próxima aula!*